

GUÍA DE PRESENTACIÓN · 15–18 MINUTOS

AudioCraft de Meta AI

Contenido completo para exponer, diseño de slides y material de apoyo — Partes 1 a 4.

4 partes teóricas

13 slides

Lanzado ago. 2023

Open Source · MIT

PARTE 01 Contexto y motivación

■ ~3 min · 3 slides

LO QUE DEBES SABER PARA EXPONER

El problema: el audio como el gran rezagado de la IA generativa

Mientras que la IA generativa explotó en texto (GPT, 2020) e imágenes (DALL·E, Stable Diffusion, 2022), el audio quedó muy atrás. Generar música o sonido de alta calidad era extremadamente difícil porque el audio es una señal de altísima dimensionalidad: una canción de pocos minutos a 44.1 kHz tiene millones de muestras, mucho más que los tokens de texto que procesan los LLMs.

Antes de AudioCraft, modelos como Jukebox (OpenAI, 2020) o Riffusion tenían serias limitaciones: eran lentos, requerían arquitecturas complejas o producían audio de baja fidelidad. No existía un framework unificado y simple para audio generativo.

Dato clave:

Una pista de 3 min a 44.1 kHz $\approx$ 8 millones de muestras. Modelos de texto como LLaMA procesan solo unos pocos miles de tokens por muestra. Este gap de escala es el reto fundamental que resuelve AudioCraft.

¿Qué es AudioCraft?

AudioCraft es un framework open-source de Meta AI (equipo FAIR) anunciado el 2 de agosto de 2023. No es un solo modelo: es una suite de herramientas y modelos de generación y compresión de audio, construida sobre PyTorch. Un solo codebase para múltiples tareas de audio generativo.

- Publicado en GitHub bajo licencia MIT (código) y CC-BY-NC 4.0 (pesos)
- Incluye tres modelos principales: MusicGen, AudioGen y EnCodec
- Requiere Python 3.9+ y PyTorch 2.1.0
- Pesos disponibles en Hugging Face para descarga directa

■ DISEÑO DE SLIDES

SLIDE 01

¿Por qué el audio se quedó atrás?

- Texto → GPT (2020) · Imagen → DALL·E (2022)
- Audio = millones de muestras por segundo
- Modelos anteriores: lentos o de baja calidad

Timeline IA generativa

8M muestras vs 4K tokens

Tip: Abre con una pregunta al público. Crea contraste inmediato.

SLIDE 02

El costo real de producir audio

- Músico profesional: \$500–\$5,000 por pista
- Licencias de stock: \$30–\$500 por tema
- Indie dev / creador pequeño sin opciones

Tabla costos comparativos

Tip: Este slide genera empatía — habla del youtuber con copyright strikes.

SLIDE 03

AudioCraft: la propuesta de Meta

- Framework open-source · Meta FAIR · Agosto 2023...
- Suite unificada: un codebase, múltiples modelos
- Genera audio de alta calidad desde texto
- Disponible en GitHub + Hugging Face

Logo AudioCraft

Timeline: jun → ago 2023

Tip: Menciona que MusicGen salió primero (jun 2023) y AudioCraft como suite en agosto.

PARTE 02 Los tres modelos de AudioCraft

■ ~5 min · 4 Slides

LO QUE DEBES SABER PARA EXPONER

EnCodec — El codec neuronal que lo hace posible

EnCodec es el componente más técnico y la base sobre la que funcionan MusicGen y AudioGen. Usa redes neuronales para aprender a representar el audio en vectores discretos (tokens) mediante cuantización vectorial (VQ). El proceso: audio crudo → tokens discretos → Transformer → tokens → decoder → audio. Los tokens son las "palabras" del audio.

Analogía para explicar: imagina convertir un video en una secuencia de emojis que captura la esencia de cada escena. EnCodec es el "diccionario" de ese idioma de audio.

MusicGen — Texto a Música

Transformer autoregresivo de etapa única entrenado sobre tokens EnCodec de 32kHz con 4 codebooks. Entrenado en 20,000 horas de música licenciada: 10,000 pistas de Meta Music Initiative, Shutterstock y Pond5. Meta removió voces del dataset para no replicar artistas.

Variante	Parámetros	Capacidad	GPU mín.
small	300M	Solo texto → música	~8 GB VRAM
medium	1.5B	Solo texto → música	~16 GB VRAM
melody	1.5B	Texto + melodía → música	~16 GB VRAM
large	3.3B	Solo texto → música (máx. calidad)	~32 GB VRAM

AudioGen — Texto a Efectos de Sonido

Misma arquitectura base que MusicGen pero especializado en sonidos ambientales y efectos, no música. Entrenado en efectos de sonido públicos. Genera clips de 5 segundos por defecto. Ejemplos: lluvia, sirenas, patos en un lago, cruce ferroviario con tren pasando.

- Videojuegos: efectos procedurales y ambientes
- Cine / realidad virtual: escenas sonoras inmersivas

■ DISEÑO DE SLIDES

SLIDE 04

La suite AudioCraft: 3 modelos

- EnCodec → compresión neuronal de audio
- MusicGen → texto a música
- AudioGen → texto a sonidos ambientales

Diagrama de 3 cajas / stack

Tip: Dibuja 3 cajas. EnCodec en la base, MusicGen y AudioGen encima

SLIDE 05

EnCodec: convirtiendo audio en tokens

- Audio crudo → tokens discretos (VQ)
- 4 codebooks en paralelo a 50 Hz
- El "idioma" que habla el Transformer

Diagrama encoder/decoder

Waveform → tokens → waveform

Tip: Dibuja: ola de audio → caja EnCodec → números → ola. Usa la analogía emoji.

SLIDE 06

MusicGen: de prompt a canción

- 4 tamaños: 300M → 3.3B parámetros
- 20,000h de música licenciada
- Condicionamiento por texto o melodía
- Sin voces — 100% instrumental

Tabla de variantes

Ejemplos de prompts

Tip: Incluye 2–3 prompts ejemplo en texto grande para que la audiencia vea

SLIDE 07

AudioGen: el mundo sonoro en texto

- Efectos y ambientes, no música
- Entrenado en efectos de sonido públicos
- Genera clips de ~5 segundos
- Ideal para juegos, cine, VR

Iconos: juego, film, VR

Tip: Contrasta con MusicGen — estructura larga vs escenas cortas e inmediatas.

PARTE 03 ¿Cómo funciona por dentro?

■ ~3 min · 3 slides

LO QUE DEBES SABER PARA EXPONER

Arquitectura general: el flujo completo

- Encoding del texto: el prompt pasa por T5 (encoder de Google) que convierte palabras en embeddings semánticos.
- Conditioning: los embeddings de T5 se inyectan al Transformer vía bloques de cross-attention.
- Generación autoregresiva: el Transformer genera tokens EnCodec de a uno, 50 pasos por segundo de audio. Los 4 codebooks se generan en paralelo con un pequeño delay entre ellos — la innovación clave.
- Decoding: los tokens generados pasan por el decoder de EnCodec y se reconstruye la señal .wav.

La innovación: generación de codebooks en paralelo

Modelos anteriores como MusicLM de Google requerían múltiples modelos en cascada. MusicGen lo hace en un solo modelo gracias a un patrón de interleaving con delay entre los 4 codebooks. Resultado: solo 50 pasos autoregresivos por segundo de audio — mucho más eficiente que difusión.

¿Qué lo diferencia de Suno y Udio?

Característica	AudioCraft	Suno / Udio
Código fuente	Open source (MIT)	Cerrado / propietario
Pesos del modelo	Disponibles (CC-BY-NC 4.0)	No disponibles
Voces / letras	No (solo instrumental)	Sí
Interfaz de usuario	Solo API / código	Web app amigable
Fine-tuning propio	Sí, con tu propio dataset	No
Costo	Gratis (requiere GPU)	Freemium / suscripción

■ DISEÑO DE SLIDES

SLIDE 08

El pipeline: de texto a audio

- Prompt → T5 encoder → embeddings
- Cross-attention → Transformer genera tokens
- Tokens → EnCodec decoder → .wav

Diagrama de flujo horizontal

Tip: Dibuja el flujo como cajas en línea. Anímalo step by step si puedes.

SLIDE 09

La innovación: 1 modelo, 4 codebooks

- Antes: múltiples modelos en cascada
- Ahora: un solo Transformer con delay pattern
- 50 pasos autoregresivos por segundo

Diagrama codebook interleaving

Tip: Muestra grid de 4 filas con tokens desplazados. No te extiendas en la técnica.

SLIDE 10

AudioCraft vs Suno / Udio

- Open source vs propietario
- Sin voces vs con voces y letras
- Control total vs facilidad de uso

Tabla comparativa

Tip: Usa checkmarks (✓ ✗) en la tabla. No es "mejor" — es diferente.

PARTE 04 Casos de uso, limitaciones y ética

■ ~2 min · 2 slides

LO QUE DEBES SABER PARA EXPONER

Aplicaciones reales

- Videojuegos: música adaptativa y efectos sin royalties. Ej: mapa que genera su propia música según bioma.
- Cine y YouTube: bandas sonoras para films indie. Los YouTubers evitan copyright strikes.
- Podcasts y radio: jingles, música de fondo contextual, transiciones entre segmentos.
- Publicidad digital: múltiples variaciones de un jingle para A/B testing en minutos.
- Realidad virtual / metaverso: entornos sonoros procedurales y adaptativos.
- Educación musical: ejemplos didácticos de géneros e instrumentos al instante.

Limitaciones honestas

- Duración fluida limitada a ~30 segundos antes de que baje la coherencia musical.
- No genera voces ni letras — decisión deliberada de Meta.
- Calidad varía mucho según el tamaño del modelo usado.
- Requiere GPU; en CPU es extremadamente lento.
- Sesgo occidental: genera mejor música anglosajona y electrónica que latinoamericana, africana o asiática.

Consideraciones éticas

Meta reconoce que el modelo podría usarse para deepfake de voz y que los derechos de autor del audio generado están en zona gris legal. El dataset tiene sesgo: entrenado principalmente en música occidental con metadatos en inglés. Pregunta abierta: ¿reemplaza o libera a los músicos?

■ DISEÑO DE SLIDES

SLIDE 11

¿Dónde se usa AudioCraft?

- Videojuegos — música adaptativa sin royalties
- Cine / YouTube — bandas sonoras indie
- Publicidad — jingles en minutos
- VR / Metaverso — ambientes sonoros

Grid de íconos por industria

Tip: Grid 2×2 de íconos por industria. Sin texto largo — solo la industria.

SLIDE 12

Limitaciones y ética

- Max ~30s de coherencia musical
- Sesgo hacia música occidental
- Derechos de autor en zona gris
- Sin voces — limitación deliberada

Iconos de advertencia

Tip: Termina con pregunta abierta "¿reemplaza o libera a los músicos?" — genera debate.

PARTE ■ Costos: ¿cuánto cuesta usar AudioCraft?

Puedes incluir en Parte 1 o como slide extra en Parte 4

LO QUE DEBES SABER PARA EXPONER

AudioCraft es gratis — pero la GPU no

El framework es completamente gratuito (MIT). Lo que tiene costo es la infraestructura de cómputo, ya que requiere GPU con al menos 8–16 GB de VRAM según el modelo.

Opción	Plataforma	Costo aprox.	Descripción
Framework / código	GitHub	\$0	Open source, MIT License
Experimentar	Google Colab gratuito (T4)	\$0	Perfecto para demos y aprendizaje
Proyectos personales	Colab Pro	~\$10/mes	GPU más potente, más tiempo de sesión
Cloud flexible	RunPod RTX 4090	~\$0.74/hr	Paga solo lo que uses
Modelos grandes	RunPod H100	~\$3.49/hr	Para el modelo large (3.3B) o lotes
Sin infraestructura	Replicate API	~\$0.005/seg	API de terceros, sin gestionar GPUs

Para la demo de hoy:

Google Colab gratuito con GPU T4 es suficiente para correr musicgen-small (300M parámetros) y generar clips de 8–15 segundos. El modelo small funciona con menos de 8 GB de VRAM. Costo total de la demo: \$0.

Contexto de costo real:

Generar un clip de 15 segundos con el modelo small en Colab tarda ~30–60 segundos y es gratis. En RunPod equivale a menos de \$0.01. Comparado con una licencia de música de stock (\$30–\$500 por pista), el ahorro es dramático.

Escenario	Plataforma recomendada	Costo aprox.	Perfil
Experimentar / aprender	Google Colab gratuito	\$0	Estudiantes, demos
Proyectos personales	Colab Pro / RunPod spot	\$10–\$30/mes	Indie devs, youtubers
Producción semi-pro	RunPod on-demand	\$50–\$200/mes	Estudios pequeños
Integración en app	Replicate / Modal API	Por uso	Startups, productos

SLIDE 13 (opcional)

¿Cuánto cuesta realmente?

- Framework: gratis (MIT)
- Colab T4: gratis para experimentar
- RunPod RTX 4090: ~\$0.74/hr
- vs licencia stock: \$30–\$500/pista

Comparativa costos visual

Barra: licencia vs AI

Tip: Comparación visual dramática — barra alta (\$300 licencia) vs barra mínima (\$0.01 con AI).